

RAPPORT DE STAGE

**Analyse d'indicateurs sur la vie scolaire et extra-scolaire des
élèves de l'INSA Toulouse**

Stage du : 1er Juillet au 30 Septembre 2024

Encadrant de stage : Mr. Jean-Yves Dauxois

Tuteur de stage : Mr. Frederic de Gournay

Etudiant : Phuc Luan Nguyen

Formation : Génie Mathématique et Modélisation

Année scolaire : 2023 - 2024

Remerciements

Je tiens à exprimer mes sincères remerciements à toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce stage et de ce rapport.

Tout d'abord, je tiens à remercier chaleureusement Monsieur Jean-Yves Dauxois, mon encadrant de stage. Bien que ce stage se soit déroulé durant une période de fin d'année scolaire, une période chargée pour lui et de vacances d'été, il a néanmoins pris le temps d'organiser des réunions régulières et de me prodiguer des conseils précieux. Grâce à son accompagnement, j'ai pu progresser dans ce sujet et enrichir mes connaissances tout au long de cette expérience professionnelle.

Ensuite, je tiens également à exprimer ma gratitude à Madame Marie Agnès Detourbe pour m'avoir aidé à acquérir une perspective plus globale sur les sciences humaines et sociales, en lien avec le sujet de mon stage.

Enfin, je souhaite remercier Paul Delon et Elsa Danh-Nghet, mes camarades de classe, qui avaient travaillé sur ce sujet lors du semestre précédent. Bien qu'eux aussi soient en pleine période de stage, ils ont trouvé le temps de me rencontrer et de partager avec moi leurs expériences et leurs conseils sur ce projet.

Merci à tous pour votre aide précieuse et pour avoir fait de ce stage une expérience mémorable et enrichissante.

Contents

Remerciements	1
Chapitre 1 : Introduction	3
1.1. Contexte du stage	3
1.2. Objectif	3
1.3. Etat de l'art au début du stage	3
Chapitre 2 : Méthodologie	4
2.1. Préparer les données	4
2.1.1. Découvrir des données	4
2.1.2. Traitement des données	5
2.2. Analyse statistique descriptive	12
2.3. Construire des modèles	12
2.3.1. Le choix du jeu de données et des variables cibles	12
2.3.2. Le choix du modèle	13
2.3.3. Des idées principales concernant Random Forest et la Régression Logistique Multinomiale	13
Chapitre 3 : Résultats	16
3.1. Pour tous étudiants	16
3.2. Pour les étudiants qui ne sont pas 1A ou nouveaux entrants (NE)	20
3.3. Pour les étudiants 4A	25
Chapitre 4 : Conclusion et discussion	29
4.1. Conclusion et recommandations	29
4.2. Limites et améliorations futures	30
Annexe A: Statistique descriptive	31
Annexe B: Certificat de cours	33
Références	33

Chapitre 1 : Introduction

1.1. Contexte du stage

Dans un monde en évolution rapide, les établissements d'enseignement supérieur doivent faire face à une pression croissante pour répondre aux attentes des différentes parties prenantes. D'une part, on demande aux universités de former des étudiants capables de s'adapter à un marché du travail en constante évolution, et d'autre part, elles doivent également veiller à ce que les étudiants évoluent dans un environnement qui favorise à la fois leur réussite scolaire et leur bien-être personnel.

Ainsi, au-delà de l'évaluation classique des acquis des étudiants en termes de savoirs, de compétences et de capacités, les universités des deux côtés de l'Atlantique ont commencé à mesurer l'expérience d'apprentissage des étudiants à l'échelle nationale grâce à des enquêtes. Alors que l'évaluation des connaissances fait depuis toujours partie des missions fondamentales des enseignants, l'intérêt pour l'évaluation des expériences d'apprentissage des étudiants gagne de plus en plus en importance, tant auprès des éducateurs que des décideurs politiques. Ce phénomène est en lien avec les tendances actuelles en matière d'assurance qualité, où la satisfaction des « usagers » est devenue un point central^[1].

1.2. Objectif

Dans cette même perspective, outre le succès académique des étudiants de l'INSA Toulouse, qui constitue une préoccupation majeure pour la Direction de l'école, l'INSA vise également à offrir le meilleur environnement possible à ses étudiants, afin qu'ils puissent réaliser pleinement leur potentiel. Cela peut inclure la réussite académique, l'accomplissement d'objectifs personnels, la création de liens sociaux et la conduite d'une vie épanouissante. Par conséquent, notre étude vise à établir des liens entre la réussite académique et les facteurs liés à la vie étudiante, afin de mieux comprendre les difficultés que certaines catégories d'étudiants pourraient rencontrer. Cela permettrait non seulement d'améliorer les résultats scolaires, mais aussi d'offrir le meilleur environnement possible aux étudiants pour enrichir leur expérience universitaire.

1.3. Etat de l'art au début du stage

La National Survey of Student Engagement (NSSE) aux États-Unis et la National Student Survey (NSS) au Royaume-Uni ont été créées pour donner plus de poids à la voix des étudiants dans les discussions sur la qualité de l'enseignement supérieur. En comparant ces deux enquêtes, on voit qu'elles adoptent toutes deux une approche axée sur les étudiants, mais elles se distinguent par leurs objectifs et leur contenu. Le NSSE met l'accent sur l'engagement des étudiants dans différentes pratiques éducatives, organisées autour de cinq thèmes : l'exposition à des méthodes éducatives efficaces, la gestion du temps, les bénéfices perçus de l'apprentissage, la qualité des interactions, et le soutien apporté par l'institution. De son côté, le NSS se concentre sur la satisfaction des étudiants quant à leur expérience d'apprentissage, en évaluant sept aspects : la qualité de l'enseignement, l'évaluation et les retours, le soutien académique, l'organisation, les ressources d'apprentissage, le développement personnel, et la satisfaction globale. Ce focus sur la satisfaction traduit une approche plus « client », où les étudiants sont perçus comme des consommateurs de l'enseignement^[1].

En Australie, le bien-être psychologique des étudiants devient aussi un sujet de plus en plus important. Une étude sur le bien-être des étudiants australiens^[2] a montré que des expériences académiques et sociales positives jouent un rôle crucial dans leur bien-être, alors que l'isolement et les pressions liées aux études peuvent avoir des impacts négatifs.

Ce stage s'inscrit dans la continuité du travail d'un groupe dans le cadre d'un projet de recherche et d'innovation de 4GMM, car le jeu de données utilisé dans ce stage a été obtenu en fin de semestre, ce qui n'a pas laissé beaucoup de temps au groupe de projet pour l'analyser. Dans ce jeu de données, nous nous intéressons particulièrement à l'impact des conditions de vie des étudiants, telles que le logement, les conditions de travail personnelles, les relations sociales, la participation à des activités associatives ou sportives, etc., ainsi que des aspects académiques comme la participation aux cours, le temps consacré aux études, l'année d'études ou la spécialité, sur les résultats scolaires et le bien-être des étudiants.

Chapitre 2 : Méthodologie

Idee générale : Dans le but d'identifier les indicateurs ayant un impact sur la réussite des étudiants à partir du jeu de données obtenu par l'enquête réalisée en mai 2024, nous construirons des modèles capables de modéliser une variable décrivant la réussite des étudiants à l'aide des autres variables. Ensuite, nous identifierons les variables importantes dans ces modèles. Pour cela, nous devons passer par les étapes de préparation des données et d'analyse descriptive des variables avant de plonger dans une analyse approfondie ou dans des modèles complexes.

2.1. Préparer les données

2.1.1. Découvrir des données

Nous disposons des données collectées lors d'une enquête menée par des étudiants de l'INSA Toulouse en mai 2024, réalisée via l'application Limesurvey. Ces données sont présentées dans un fichier Excel de 1182 lignes, où chaque ligne représente un étudiant et chaque colonne correspond à une réponse. En complément, nous avons un fichier PDF intitulé "Statistiques rapides" qui décrit la distribution des réponses pour chaque question, ce qui nous permet d'avoir une première vision des questions et des données.

Ci-dessous se trouve un résumé de la signification des 60 variables correspondant aux 60 questions posées dans le questionnaire:

Variable	Description	Modalités
TRAJET	Durée quotidienne du trajet (min)	0-5, 5-15, 15-30, Plus de 30 min
LOGEMENTTYPE	Type de logement	Seul, Colocation, Foyer familial
LOGEMENTSURFACE	Surface du logement (m ²)	Moins de 10, 10-20, 20-30, Plus de 30, Non affiché
LOGEMENTBIEN	Niveau de confort dans le logement	Tout à fait, Plutôt oui, Plutôt non, Pas du tout
ACT_PRO	Temps d'activité professionnelle à côté de vos études par semaine	Non, 1-5h, 5-10h, 10-15h, Plus de 15h
BOURSIER	Échelon de bourse	Non, 0bis, 1, 2, 3, 4, 5, 6, 7
HANDICAP	Situation de handicap	Non, Oui
TIERSTEMPS	Tiers-temps pour les examens	Non, Oui
STRESS	Fréquence de stress	Toujours, Souvent, Parfois, Jamais
COMMENTAIRE	Fréquence de retour des enseignants	Toujours, Souvent, Parfois, Jamais
COMCONSTRUCTIFS	Nature des commentaires constructifs	Tout à fait, Plutôt oui, Plutôt non, Non, Non affiché
ETUDE_SEM	Temps de travail personnel en semaine	Plus de 4h, 2-4h, 1-2h, Moins d'1h, Pas du tout
ETUDEWE	Temps de travail personnel le week-end	Plus de 8h, 6-8h, 4-6h, 2-4h, 1-2h, Moins d'1h, Pas du tout
ETUDEGROUPE	Fréquence des études en groupe	Toujours, Souvent, Parfois, Jamais
PRESENCE_CM	Fréquence de présence aux CM	Toujours, Souvent, Parfois, Jamais
PRESENCE_TD	Fréquence de présence aux TD	Toujours, Souvent, Parfois, Jamais
PRESENCE_TP	Fréquence de présence aux TP	Toujours, Souvent, Parfois, Jamais
CONCENTRATION_CM	Niveau de concentration pendant les CM	Totalement, Assez bien, Moyennement, Très peu
CONCENTRATION_TD	Niveau de concentration pendant les TD	Totalement, Assez bien, Moyennement, Très peu
CONCENTRATION_TP	Niveau de concentration pendant les TP	Totalement, Assez bien, Moyennement, Très peu
PREPCOURS_CM	Fréquence de préparation des CM	Toujours, Souvent, Parfois, Jamais
PREPCOURS_TD	Fréquence de préparation des TD	Toujours, Souvent, Parfois, Jamais
PREPCOURS_TP	Fréquence de préparation des TP	Toujours, Souvent, Parfois, Jamais
COURSNOTES_CM	Fréquence de prise de notes en CM	Toujours, Souvent, Parfois, Jamais
COURSNOTES_TD	Fréquence de prise de notes en TD	Toujours, Souvent, Parfois, Jamais
COURSNOTES_TP	Fréquence de prise de notes en TP	Toujours, Souvent, Parfois, Jamais
REVISIONSDEB	Début des révisions pour un examen	Tout au long du semestre, Un mois avant, Deux semaines avant, Une semaine avant, 3/4 jours avant, La veille
CONCENTRATIONPERSO	Niveau de concentration pendant le travail personnel	Très concentré.e, Plutôt concentré.e, Moyennement concentré.e, Pas du tout concentré.e
CONDITIONSTRAVAIL	Conditions de travail personnel	Très bonnes, Bonnes, Moyennes, Mauvaises
RESSOURCES_SUP	Utilisation de ressources supplémentaires	Très souvent, Régulièrement, Parfois, Jamais

AMIS	Fréquence des rencontres avec des amis	Toujours, Souvent, Parfois, Jamais
FAMILLE	Fréquence des rencontres avec la famille	Toujours, Souvent, Parfois, Jamais
ISOLEMENT	Sentiment d'isolement social	Toujours, Souvent, Parfois, Jamais
ASSOCIATIF	Implication dans la vie associative	Plus de 20h, 15-20h, 10-15h, 5-10h, 1-5h, Moins d'une heure, Non
ASSOCIATIF_POSITIF	Impact positif de la vie associative	Tout à fait, Plutôt oui, Plutôt non, Pas du tout, Non affiché
ASSOCIATIF_FATIGUE	Impact de la vie associative sur la fatigue	Tout à fait, Plutôt oui, Plutôt non, Pas du tout, Non affiché
SPORTTEMPS	Temps consacré au sport par semaine	Plus de 10h, 6-10h, 3-6h, 1-3h, Moins d'une heure
SPECTACLES	Fréquence de participation à des spectacles	Au moins 1 fois par semaine, 1 fois par mois, Rarement, Jamais
SPECTACLES_POSITIF	Impact des spectacles sur le bien-être	Tout à fait, Plutôt oui, Plutôt non, Pas du tout, Non affiché
SORTIEBAR	Fréquence de sorties en bar	Tous les jours, Plusieurs fois par semaine, 1 fois par semaine, 1 fois par mois, Rarement, Jamais
DETENTE	Fréquence des moments de détente	Très souvent, Régulièrement, Parfois, Jamais
ECRANS	Temps passé devant les écrans par jour	Plus de 8h, 6-8h, 4-6h, 2-4h, 1-2h, Moins d'une heure
SOMMEIL	Qualité du sommeil	Très satisfaisante, Satisfaisante, Plutôt insatisfaisante, Pas satisfaisante
ALIMENTATION	Qualité de l'alimentation	Tout à fait, Plutôt oui, Plutôt non, Pas du tout
MOTIVATION	Niveau de motivation par études à l'INSA	Tout à fait, Plutôt oui, Plutôt non, Pas du tout
SENSATIONREUSSITE	Sentiment de réussite études à l'INSA	Tout à fait, Plutôt oui, Plutôt non, Pas du tout
ADEQUATION	Correspondance entre les études et projet professionnel	Tout à fait, Plutôt oui, Plutôt non, Pas du tout
PREPMETIER	Préparation pour réaliser projet professionnel	Tout à fait, Plutôt oui, Plutôt non, Pas du tout
PROMO	Année scolaire en cours	1A, 2A, 3A, 4A, 5A
SPECIALITE_PO	Spécialité ou pré-orientation choisie	1A, ICBE, IMACS, MIC, IC, GB, GP3E, GP, AE, MA, IR, GC, GM, apprentissage
COHORTE	Cohorte de l'étudiant	FAS, NORGINS, IBERINSA, ENGINS, AINS, SHN, Pas de cohorte particulière, etc.
DOUBLEDIPLOME	Participation à un double diplôme	Non, Oui
INTEGRATION	Année d'intégration à l'INSA	Après bac, 1A, 2A, 3A, 4A
BACTYPE	Type de baccalauréat	BAC en France, BAC français à l'étranger, Diplôme équivalent en France, Diplôme équivalent à l'étranger
CLASSEMENT1A	Classement en première année	0-10%, 10-25%, 25-50%, 50-75%, 75-100%
CLASSEMENTDERNIER	Classement à la dernière année	0-10%, 10-25%, 25-50%, 50-75%, 75-100%
REDOUBLEMENT	Répétition d'une année	Non, Oui
RATRAPAGES	Nombre de rattrapages par semestre	Aucun, Un, Deux/trois, Plus de quatre

Table 1: Tableau : Variables et descriptions

2.1.2. Traitement des données

Transformer des données

Étant donné que les questions sont sous forme de QCM, les réponses sont enregistrées sous forme de variables indicatrices. Par conséquent, pour effectuer les premières analyses, nous devons d'abord convertir ces colonnes en une seule colonne. À cette étape, je me suis basé sur les résultats du fichier Excel des trois membres de l'équipe qui ont travaillé sur le projet précédent. Nous utilisons une formule conditionnelle dans Excel : si la valeur de la colonne est 'oui', elle renverra le résultat correspondant à la valeur de cette colonne. Cependant, après vérification, j'ai constaté qu'ils n'ont pas pris en compte les données de certaines questions, comme COMMENTAIRE, COURSNOTES (TD), COURSNOTES (TP), CONCENTRATIONPERSO, LOISIRSIMPACT, PREPMETIER, DOUBLEDIPLOME. Ils ont expliqué que cela était dû au fait qu'ils estimaient que ces variables pouvaient avoir une forte corrélation avec une autre variable, ou que ces variables avaient un taux élevé de valeurs non affichées, ou que tous les résultats se concentraient sur une seule valeur, etc. Mais je pense que cela n'est qu'une partie de leur ressenti, car ils n'ont pas utilisé de méthodes théoriques pour vérifier. Je souhaite donc utiliser tous les résultats des questions du sondage, vérifier le taux de données manquantes ou la corrélation des variables, puis les traiter ensuite, c'est pourquoi j'ai refait ce processus de conversion pour obtenir un ensemble de données comprenant toutes les variables.

En outre, pour les questions avec des valeurs de choix 'Autre', où les répondants devaient entrer leur propre réponse, comme pour LOGEMENTTYPE, nous avons remarqué qu'il n'y avait pas beaucoup de valeurs 'Autre'. Nous avons donc regroupé manuellement ces valeurs 'Autre' en catégories existantes. Par exemple, 'concubinage', 'avec ma copine', 'en couple', 'avec mon frère', 'chez un ami' ont été regroupés sous 'colocation', et 'CROUS', 'Logement étudiant', 'maison individuelle' ont été regroupés sous 'seul'. De plus, pour la variable DOUBLEDIPLOME, je recode les réponses choisies 'Autre' en 'Oui' ou 'Non'. Pour les cas indiquant une demande en cours, un souhait d'étudier ou une intention d'étudier l'année prochaine, je les recode en 'Non'. Selon moi, notre étude se base sur les variables cibles, qui sont les résultats d'apprentissage des années précédentes. Par conséquent, si la double diplomation est envisagée à l'avenir, cela n'a pas encore d'impact sur la variable cible.

```
glimpse(insa, width = 82)
```

```
## Rows: 1,182
## Columns: 60
## $ TRAJET <chr> "15-30min", "5-15min", "0-5min", "5-15min", "5-15min"~
## $ LOGEMENTTYPE <chr> "seul", "seul", "seul", "seul", "colocation", "coloca~
## $ LOGEMENTSURFACE <chr> "+ 30m2", "+ 30m2", "10-20m2", "+ 30m2", "coloc ou fo~
## $ LOGEMENTBIEN <chr> "tout à fait", "tout à fait", "plutôt oui", "tout à f~
## $ ACT_PRO <chr> "aucune", "aucune", "aucune", "aucune", "aucune", "ou~
## $ BOURSIER <chr> "echelon 1-3", "non", "non", "non", "non", "non", "no~
## $ HANDICAP <chr> "non", "non", "non", "non", "non", "non", "non", "non~
## $ TIERSTEMPS <chr> "Non", "Non", "Non", "Non", "Oui", "Non", "Non", "Non~
## $ STRESS <chr> "souvent", "souvent", "souvent", "toujours", "souvent~
## $ COMMENTAIRE <chr> "jamais", "parfois", "parfois", "parfois", "parfois",~
## $ COMCONSTRUCTIFS <chr> "pas commentaire", "plutôt oui", "plutôt oui", "plutô~
## $ ETUDE_SEM <chr> "0-1h", "+4h", "1-2h", "1-2h", "0-1h", "0-1h", "0-1h"~
## $ ETUDEWE <chr> "2-4h", "2-4h", "4-6h", "6-8h", "4-6h", "1-2h", "1-2h~
## $ ETUDEGROUPE <chr> "jamais", "jamais", "parfois", "parfois", "parfois", ~
## $ ETUDEDEHORS <chr> "souvent", "parfois", "parfois", "parfois", "souvent"~
## $ ETUDEDOM <chr> "parfois", "souvent", "souvent", "toujours", "jamais"~
## $ PRESENCE_CM <chr> "Souvent", "Toujours", "Toujours", "Toujours", "Souve~
## $ PRESENCE_TD <chr> "Toujours", "Toujours", "Toujours", "Toujours", "Touj~
## $ PRESENCE_TP <chr> "Toujours", "Toujours", "Toujours", "Toujours", "Touj~
## $ CONCENTRATION_CM <chr> "Très peu concentré.e", "Totalelement concentré.e", "As~
## $ CONCENTRATION_TD <chr> "Moyennement concentré.e", "Totalelement concentré.e", ~
## $ CONCENTRATION_TP <chr> "Assez bien concentré.e", "Assez bien concentré.e", "~
## $ PREPCOURS_CM <chr> "Jamais", "Jamais", "Parfois", "Parfois", "Jamais", "~
## $ PREPCOURS_TD <chr> "Jamais", "Souvent", "Souvent", "Parfois", "Parfois",~
## $ PREPCOURS_TP <chr> "Jamais", "Souvent", "Parfois", "Souvent", "Toujours"~
## $ COURSNOTES_CM <chr> "Parfois", "Toujours", "Souvent", "Toujours", "Parfoi~
## $ COURSNOTES_TD <chr> "Toujours", "Toujours", "Souvent", "Toujours", "Toujo~
## $ COURSNOTES_TP <chr> "Parfois", "Toujours", "Jamais", "Toujours", "Toujour~
## $ REVISIONSDEB <chr> "2 semaines avant", "2 semaines avant", "1 mois avant~
## $ CONCENTRATIONPERSONO <chr> "pas du tout", "très", "plutôt oui", "moyennement", "~
## $ CONDITIONSTRAVAIL <chr> "très bonnes", "très bonnes", "moyennes", "plutôt bon~
## $ RESSOURCES_SUP <chr> "jamais", "régulièrement", "très souvent", "parfois",~
## $ AMIS <chr> "régulièrement", "régulièrement", "jamais", "régulière~
## $ FAMILLE <chr> "parfois", "régulièrement", "parfois", "parfois", "pa~
## $ ISOLEMENT <chr> "souvent", "jamais", "parfois", "souvent", "jamais", ~
## $ ASSOCIATIF <chr> "10-15h", "0-1h", "non", "1-5h", "5-10h", "non", "non~
## $ ASSOCIATIF_POSITIF <chr> "tout à fait", "plutôt non", "pas d'asso", "plutôt ou~
## $ ASSOCIATIFFATIGUE <chr> "tout à fait", "pas du tout", "pas d'asso", "plutôt n~
## $ SPORTTEMPS <chr> "0-1h", "3-6h", "1-3h", "1-3h", "0-1h", "0-1h", "3-6h~
## $ SPECTACLES <chr> "jamais", "1/mois", "jamais", "rarement", "rarement",~
## $ SPECTACLES_POSITIF <chr> "pas de spectacles", "plutôt oui", "pas de spectacles~
```

```
## $ SORTIEBAR      <chr> "rarement", "1/semaine", "jamais", "jamais", "1/mois"~
## $ DETENTE       <chr> "régulièrement", "parfois", "parfois", "très souvent"~
## $ ECRANS        <chr> "4-6h", "1-2h", "2-4h", "2-4h", "2-4h", "6-8h", "4-6h"~
## $ SOMMEIL       <chr> "plutôt satisfaisante", "plutôt satisfaisante", "plut~
## $ ALIMENTATION  <chr> "plutôt non", "tout à fait", "plutôt non", "plutôt ou~
## $ MOTIVATION    <chr> "plutôt non", "tout à fait", "plutôt oui", "plutôt no~
## $ SENSATIONREUSSITE <chr> "plutôt non", "tout à fait", "plutôt oui", "plutôt ou~
## $ ADEQUATION    <chr> "plutôt oui", "tout à fait", "plutôt oui", "plutôt no~
## $ PREPMETIER    <chr> "plutôt oui", "tout à fait", "plutôt oui", "plutôt ou~
## $ PROMO         <chr> "4A", "4A", "4A", "4A", "4A", "4A", "3A", "3A", "3A",~
## $ SPECIALITE_PO <chr> "GMM", "GMM", "GMM", "GB", "GB", "GB", "GB", "GB", "GB", "G~
## $ COHORTE       <chr> "classique", "classique", "classique", "classique", "~
## $ DOUBLEDIPLOME <chr> "non", "oui", "non", "non", "non", "non", "non", "non", "non~
## $ INTEGRATION   <chr> "3A", "post-bac", "1A", "post-bac", "3A", "post-bac",~
## $ BACTYPE       <chr> "Fr", "Fr", "Fr", "Fr", "Fr", "Fr", "Fr", "Fr", "Fr_etrange~
## $ CLASSEMENT1A  <chr> "pas de classement", "0-10%", "50-75%", "25-50%", "pa~
## $ CLASSEMENTDERNIER <chr> "25-50%", "0-10%", "25-50%", "10-25%", "50-75%", "jsp~
## $ REDOUBLEMENT  <chr> "Non", "Non", "Non", "Non", "Oui", "Oui", "Non", "Non~
## $ RATRAPAGES    <chr> "aucun", "aucun", "aucun", "aucun", "1 par semestre",~
```

Nous constatons que nos données comprennent 60 colonnes correspondant à 60 variables (sans compter la colonne ID) et 1182 lignes représentant les réponses de 1182 étudiants. Cependant, les valeurs des variables sont actuellement encodées sous forme de chaînes de caractères (chr[]), alors qu'elles devraient être encodées sous forme de facteurs pour les variables qualitatives. Par conséquent, nous procéderons à la conversion de toutes les variables en facteurs.

Nous avons que les variables ont été converties en facteurs, mais que l'ordre des modalités est mélangé. Par conséquent, nous réorganisons l'ordre des modalités afin de faciliter le suivi des variables par la suite. Étant donné que le code pour réorganiser toutes les variables est assez long, je ne vais pas l'afficher. Je vais seulement montrer un exemple de la variable TRAJET après avoir réorganisé les modalités.




Figure 1: Distribution de la variable TRAJET avant et après réorganiser

Gérer des valeurs manquantes

```
na_counts <- sapply(insa, function(x) sum(is.na(x)))
print(na_counts[na_counts > 0])
```

```
##      LOGEMENTTYPE LOGEMENTSURFACE      RATTRAPPAGES
##              1              5              13
```

Nous constatons qu'il y a des valeurs manquantes pour deux variables, LOGEMENTTYPE et LOGEMENTSURFACE. Pour la variable LOGEMENTTYPE, il y a une option 'Autre' et un étudiant a rempli 'vélo', que nous considérons comme une valeur manquante. De plus, nous avons divisé les résultats de la variable LOGEMENTTYPE en valeurs disponibles, parmi lesquelles 5 valeurs sont classées sous 'seul'. Cependant, lorsque l'option 'Autre' est choisie, il n'y a pas de question sur LOGEMENTSURFACE. Par conséquent, les 5 personnes qui ont choisi 'Autre' du type 'seul' n'ont pas de valeur pour LOGEMENTSURFACE.

En outre, pour la variable RATTRAPPAGES, il y a une option 'Autre' permettant aux étudiants de remplir leur propre réponse, mais celles-ci ne sont pas claires. Afin d'éviter des erreurs d'information, je n'ai pas recodé ces données, ce qui laisse 13 étudiants sans données pour RATTRAPPAGES.

Comme le nombre de valeurs manquantes est faible, nous allons supprimer les individus contenant des valeurs manquantes."

```
insa_cleaned_1 <- na.omit(insa)
```

Éliminer certaines variables ayant une forte corrélation entre elles.

Étant donné que les données comprennent des variables qualitatives et que certaines questions sont interconnectées, où la réponse à une question dépend de la précédente, et que certaines questions reprennent directement le résultat de la réponse précédente, comme c'est le cas pour LOGEMENTTYPE et LOGEMENTSURFACE, COMMENTAIRE et COMCONSTRUCTIFS, ASSOCIATIF et ASSOCIATIF_POSITIF ainsi qu'ASSOCIATIFFATIGUE, SPECTACLES et SPECTACLES_POSITIF. Par exemple, si une personne choisit "jamais" à la question COMMENTAIRE, alors la réponse à COMCONSTRUCTIFS sera automatiquement "pas commentaire". Cela peut entraîner un phénomène où, lorsque nous transformons ces variables en variables indicatrices pour construire des modèles, certaines variables deviennent totalement identiques, rendant ainsi le modèle instable et peu fiable. Par conséquent, nous ne retiendrons qu'une seule variable parmi les variables traitant d'un même sujet afin d'éviter la redondance des données et également de prévenir le phénomène de multicolinéarité.

Méthode choisie : Nous analyserons toutes les variables décrivant un même sujet afin de comprendre les relations qui existent entre elles. Cependant, au final, nous ne conserverons que la variable qui décrit le mieux ce sujet.

La variable TRAJET et les variables LOGEMENTTYPE, LOGEMENTSURFACE, LOGEMENTBIEN

Nous constatons ce qui suit: - La variable TRAJET et la variable "LOGEMENTTYPE" sont dépendantes. Nous observons que les étudiants vivant seuls ont tendance à habiter plus près de l'école pour faciliter leurs déplacements, tandis que ceux ayant un temps de trajet plus long sont principalement ceux qui vivent dans la collocation ou le foyer familial. - La variable "LOGEMENTTYPE" et la variable "LOGEMENTSURFACE" sont dépendantes car les réponses aux deux questions sont liées entre elles. - La variable "LOGEMENTBIEN", d'après le test du Chi-deux, dépend également de la variable "LOGEMENTTYPE", bien que cette relation ne soit pas très évidente. De plus, la distribution de cette variable est fortement biaisée en faveur de deux modalités, "plutôt oui" et "tout à fait" (représentant plus de 95 %), ce qui rend cette variable peu informative. Ainsi, j'ai décidé de conserver seulement la variable "LOGEMENTTYPE" pour représenter les variables liées au TRAJET et au logement.

```
insa_cleaned_1 <- insa_cleaned_1 %>%
  dplyr::select (-TRAJET, -LOGEMENTSURFACE, -LOGEMENTBIEN)
```

Variable COMMENTAIRE et COMCONSTRUCTIFS

Nous constatons qu'il y a une redondance d'information entre ces deux variables. De plus, la majorité des commentaires sont constructifs, soit près de 87,7 % (67,6/77,1). Par conséquent, nous avons décidé de supprimer la variable COMCONSTRUCTIFS.

```
insa_cleaned_1 <- insa_cleaned_1 %>%  
  dplyr::select (-COMCONSTRUCTIFS)
```

Variable ETUDE_SEM, ETUDEWE

Nous constatons que le temps d'étude en semaine et le temps d'étude pendant le week-end sont généralement proportionnels. Ceux qui étudient davantage en semaine ont également tendance à étudier davantage pendant le week-end.

Ainsi, nous pouvons considérer que ces deux variables décrivent une même notion : le temps que les étudiants consacrent à leurs études en dehors des heures de cours. Je vais donc choisir de conserver la variable ETUDEWE pour représenter cette notion, car elle présente un plus grand nombre de modalités et une meilleure répartition entre celles-ci.

```
insa_cleaned_1 <- insa_cleaned_1 %>%  
  dplyr::select (-ETUDE_SEM)
```

Variable ETUDEDEHORS et ETUDEDOM

Étant donné que ces deux variables décrivent le même phénomène, par exemple, les étudiants qui étudient fréquemment à l'extérieur passent moins de temps à étudier chez eux, et inversement, on peut considérer que ces deux variables se déduisent l'une de l'autre ou partagent un sens similaire. Par conséquent, nous avons choisi de supprimer l'une des deux variables. J'ai décidé de supprimer la variable ETUDEDOM, car elle est fortement biaisée vers les choix "souvent" et "toujours", tandis que la modalité "jamais" ne représente que 3 %, ce qui pourrait rendre le modèle instable.

```
insa_cleaned_1 <- insa_cleaned_1 %>%  
  dplyr::select (-ETUDEDOM)
```

Les variables relatives aux cours magistraux (CM), aux travaux dirigés (TD) et aux travaux pratiques (TP)

Nous observons une tendance générale concernant l'implication des étudiants dans les cours magistraux (CM), les travaux dirigés (TD) et les travaux pratiques (TP), à savoir que les étudiants s'impliquent généralement davantage dans les séances de TD et de TP que dans les CM. De plus, les tests montrent une dépendance entre les variables liées à ces trois types de cours. Par conséquent, je propose de créer trois nouvelles variables : IMPLICATION_CM, IMPLICATION_TD et IMPLICATION_TP, qui regrouperaient ces aspects et permettraient de mieux évaluer l'implication des étudiants dans chacun de ces formats de cours.

```
# Calculer la moyenne des valeurs pour CM  
IMPLICATION_CM_NUM <- rowMeans(cbind(  
  as.numeric(factor(insa_cleaned_1$PRESENCE_CM,  
    levels = c("Jamais", "Parfois", "Souvent", "Toujours"))),  
  as.numeric(factor(insa_cleaned_1$CONCENTRATION_CM, levels =  
    c("Très peu concentré.e", "Moyennement concentré.e",  
      "Assez bien concentré.e", "Totalelement concentré.e"))),  
  as.numeric(factor(insa_cleaned_1$PREPCOURS_CM,  
    levels = c("Jamais", "Parfois", "Souvent", "Toujours"))),  
  as.numeric(factor(insa_cleaned_1$COURSNOTES_CM,  
    levels = c("Jamais", "Parfois", "Souvent", "Toujours")))  
, na.rm = TRUE)
```

```
# Arrondir et reconverter en modalités qualitatives
insa_cleaned_1$IMPLICATION_CM <- factor(round(IMPLICATION_CM_NUM),
                                         levels = c(1, 2, 3, 4),
                                         labels = c("Jamais", "Parfois",
                                                    "Souvent", "Toujours"))
```

De même pour les variables IMPLICATION_TD et IMPLICATION_TP

```
# Tracer chaque graphique
plot1 <- plot_distribution(insa_cleaned_1, "IMPLICATION_CM")
plot2 <- plot_distribution(insa_cleaned_1, "IMPLICATION_TD")
plot3 <- plot_distribution(insa_cleaned_1, "IMPLICATION_TP")

grid.arrange(plot1, plot2, plot3, ncol = 3)
```




Figure 2: Distribution des variables IMPLICATION_CM, IMPLICATION_TD et IMPLICATION_TP

```
# Supprimer les colonnes liées à CM, TD et TP
insa_cleaned_1 <- insa_cleaned_1 %>%
  dplyr::select(-PRESENCE_CM, -CONCENTRATION_CM, -PREPCOURS_CM, -COURSNOTES_CM,
               -PRESENCE_TD, -CONCENTRATION_TD, -PREPCOURS_TD, -COURSNOTES_TD,
               -PRESENCE_TP, -CONCENTRATION_TP, -PREPCOURS_TP, -COURSNOTES_TP)
```

Variable ASSOCIATIF, ASSOCIATIF_POSITIF, ASSOCIATIFFATIGUE

Comme les trois variables sont liées, je ne conserverai qu’une seule variable, “ASSOCIATIF”, afin d’éviter la redondance d’informations pour les étudiants non participants.

```
insa_cleaned_1 <- insa_cleaned_1 %>%  
  dplyr::select(-ASSOCIATIF_POSITIF, -ASSOCIATIFFATIGUE)
```

Variable SPECTACLES, SPECTACLES_POSITIF

Comme les deux variables présentent une redondance d’information, je ne conserverai que la variable “fréquence assistez-vous à des performances artistiques” afin d’éviter la répétition des données

```
insa_cleaned_1 <- insa_cleaned_1 %>%  
  dplyr::select(-SPECTACLES_POSITIF)
```

Nous avons également constaté que la variable TIERSTEMPS est fortement corrélée avec les variables COHORTE, BACTYPE et HANDICAP, et que ces variables décrivent assez bien la variable TIERSTEMPS. Par conséquent, je vais supprimer la variable TIERSTEMPS.

De plus, les trois variables ADEQUATION, PREPMETIER et MOTIVATION sont également fortement corrélées entre elles, ce qui est compréhensible, car les personnes qui trouvent que le programme d’études est adéquat ou bien préparé pour leur parcours professionnel auront davantage de motivation pour étudier. Par conséquent, je ne garderai que la variable MOTIVATION.

Enfin, les variables SORTIEBAR et AMIS sont fortement corrélées entre elles, ce qui est aussi compréhensible, car elles sont toutes deux liées aux interactions avec l’environnement social et amical. Par conséquent, je ne garderai que la variable AMIS.

```
insa_cleaned_1 <- insa_cleaned_1 %>%  
  dplyr::select(-TIERSTEMPS, -PREPMETIER, -ADEQUATION, -SORTIEBAR)
```

```
glimpse(insa_cleaned_1, width = 80)
```

Après avoir réalisé les étapes ci-dessus, nous sommes passés de 60 variables à 38, ce qui a permis de réduire considérablement la taille de notre ensemble de données et d’éviter la redondance des informations.

Combiner des modalités avec des fréquences d’apparition très faibles.

De plus, on voit un autre problème ici : nous avons des modalités avec des fréquences d’apparition très faibles, par exemple pour les variables LOGEMENTBIEN, ACT_PRO, ... Cela rend les estimations des paramètres de ces modalités très instables, entraînant du bruit et un surajustement du modèle. Par conséquent, la mise en commun augmente le nombre d’observations par groupe, aidant ainsi le modèle à apprendre des modèles de manière plus cohérente. De plus, regrouper les variables avec une fréquence faible mais des significations similaires aide à réduire la complexité du modèle, car chaque modalité dans une variable catégorielle crée une nouvelle dimension spatiale lorsqu’elle est codée à l’aide de la méthode de codage one-hot, entraînant une augmentation du nombre de paramètres à apprendre et un risque accru de surajustement.

Par exemple, si nous avons seulement un étudiant qui choisit SORTIEBAR_tous les jours, et que cet étudiant redouble, nous risquons un surajustement car les variables REDOUBLEMENT et SORTIEBAR_tous les jours seraient complètement corrélées.

Après avoir combiné les modalités à faible fréquence et de signification similaire, nos données seront propres et prêtes pour la construction du modèle.

```
glimpse(insa_cleaned_2, width = 80)
```

2.2. Analyse statistique descriptive

Étant donné que nous avons 43 variables, la présentation de l'analyse descriptive pour toutes les variables serait très longue. Par conséquent, j'ai seulement sélectionné les informations descriptives qui offrent un aperçu général et qui peuvent être considérées comme utiles pour nos étudiants.

Les conditions de vie de nos étudiants sont relativement bonnes:

- Pour la variable *TRAJET*, nous observons qu'environ 80 % des étudiants mettent moins de 15 minutes pour se rendre à l'école, et près de 95 % mettent moins de 30 minutes.
- Quant à la variable *LOGEMENTBIEN*, plus de 95 % des étudiants ont choisi "plutôt oui" ou "tout à fait" pour exprimer leur satisfaction. Cela montre que la grande majorité des étudiants disposent de bonnes conditions de déplacement (ne nécessitant pas beaucoup de temps) pour se rendre à l'école, et que leurs conditions de logement sont également assez satisfaisantes, avec plus de 95 % des réponses indiquant une satisfaction positive.
- Pour la variable *CONDITIONSTRAVAIL*, nous constatons que la majorité des étudiants (plus de 90 %) estiment avoir des conditions de travail personnel "plutôt bonnes" ou meilleures, et très peu (1,2 %) ont répondu avoir de "mauvaises" conditions de travail personnel, le reste ayant des conditions "moyennes". Cela montre que les étudiants bénéficient de conditions de travail personnel relativement bonnes.
- En ce qui concerne *ALIMENTATION*, plus de 80 % des étudiants ont donné des réponses positives ("plutôt oui" ou "tout à fait") sur leur alimentation.

L'implication dans les séances de cours: Concernant les variables présence, concentration, préparation et coursnote, les étudiants semblent accorder davantage de priorité aux TD et TP par rapport aux CM. Cela peut s'expliquer par le fait que notre école est une école d'ingénieurs, où les étudiants ont tendance à préférer faire des exercices ou appliquer leurs connaissances dans des travaux pratiques plutôt que d'apprendre de la théorie

Concernant les activités associatives : Parmi ceux qui sont impliqués dans des associations, 91,2 % (47,7/51,3) estiment que cette vie associative a un impact positif sur leur bien-être général. Cela montre que, globalement, la participation à des associations est bénéfique pour les étudiants. Cependant, nous constatons que près de la moitié (48,7 %) de nos étudiants ne participent pas aux activités associatives, un pourcentage relativement élevé.

Quelques variables concernant la santé mentale comme le stress et le sommeil: Un fait assez inquiétant est que plus de 61,7 % des étudiants déclarent être souvent ou toujours stressés, dont 17,7 % répondent "toujours". En outre, plus d'un tiers (36,2 %) des étudiants expriment une insatisfaction quant à leur sommeil. Ces chiffres sont relativement élevés et soulèvent des inquiétudes quant à la santé mentale des étudiants.

2.3. Construire des modèles

2.3.1. Le choix du jeu de données et des variables cibles

Au départ, en lisant l'introduction du stage dont l'objectif est de faire en sorte que tous les étudiants admis à l'INSA puissent obtenir leur diplôme, ma première pensée a été d'identifier les variables influençant la limitation du *REDOUBLEMENT* des étudiants. Cependant, cette variable apporte peu d'information, car elle se limite à indiquer si l'étudiant a redoublé ou non. Il est possible que certains étudiants n'aient pas redoublé, mais aient accumulé des dettes ou de nombreux rattrapages, ce qui n'est pas reflété par cette variable.

Ensuite, nous avons envisagé d'utiliser la variable *CLASSEMENTDERNIER* pour décrire les résultats académiques des étudiants. Cependant, un problème est survenu : environ un tiers des étudiants ont répondu "je ne sais pas" à cette question. Cela peut être dû au fait que les résultats de l'année précédente sont envoyés par e-mail en début d'année, et à la fin de l'année, certains étudiants peuvent avoir oublié leur classement. D'autres étudiants, peut-être, ne prêtent pas attention à cet e-mail, ce qui fait qu'ils ne connaissent pas leur classement.

Ainsi, notre choix suivant a été de construire un modèle en utilisant la variable *RATTRAPAGES* comme variable cible. Toutefois, après examen, nous avons constaté que pour les étudiants de première année ou les nouveaux entrants, les variables *CLASSEMENTDERNIER*, *REDOUBLEMENT* et *RATTRAPAGES* ne sont pas disponibles, car au moment de l'enquête, ils n'avaient vécu qu'un semestre à l'INSA. Nous avons donc dû choisir une autre variable cible applicable à tous les étudiants. Finalement, nous avons opté pour la variable *SENSATIONREUSSITE*, une variable relativement qualitative qui dépend du ressenti subjectif des étudiants. Néanmoins, nous croyons que le sentiment de réussite et la confiance en ses capacités à réussir reflètent également la confiance en soi et la croyance en ses capacités d'apprentissage.

Ensuite, ne pouvant pas utiliser la variable *RATTRAPAGES* pour l'ensemble des étudiants, et devant utiliser une variable plus subjective, j'ai cherché un jeu de données dans lequel une variable cible qualitative pourrait être employée. Par conséquent, je vais également construire un modèle sur le deuxième jeu de données, qui inclut les étudiants ne faisant pas partie de la première année ou des nouveaux entrants.

Enfin, en lisant des articles sur le *NSSE* et le *NSS*, j'ai constaté que ces enquêtes se concentrent souvent sur les étudiants en dernière année d'université. Cela me semble pertinent, car ces étudiants ont une expérience plus longue de leurs études, et les informations ou expériences qu'ils partagent sont plus stables. Par exemple, supposons qu'un étudiant ait rejoint l'école il y a seulement un semestre et, ne s'étant pas encore adapté, ait dû passer de nombreux rattrapages au début. Par la suite, après s'être familiarisé avec les études à l'INSA, il s'améliore et a moins de rattrapages. Ainsi, la moyenne des rattrapages est plus stable chez ceux qui ont passé plusieurs semestres que chez ceux qui n'en ont vécu qu'un ou deux. Toutefois, lorsque l'enquête a été réalisée, la plupart des étudiants de cinquième année étaient en stage, donc peu ont répondu à l'enquête. En revanche, pour les étudiants de quatrième année, plus de 350 réponses ont été obtenues, représentant un pourcentage élevé par rapport au total des étudiants de quatrième année. C'est pourquoi j'ai choisi d'analyser les données des étudiants de quatrième année, en espérant que ce jeu de données soit le plus stable en termes d'information.

2.3.2. Le choix du modèle

Pour identifier les variables importantes dans la construction d'un modèle, j'ai envisagé deux options :

- Utiliser une sélection de modèle à partir d'une régression logistique multinomiale, ou utiliser la régularisation *LASSO* pour identifier les variables importantes dans un modèle linéaire généralisé.
- Construire un modèle *Random Forest* et utiliser l'indice d'importance des variables.

Cependant, initialement, mes données n'étaient pas totalement exemptes de variables corrélées ou de redondances d'information, ce qui a causé des erreurs dans la construction du modèle de régression logistique multinomiale. Par ailleurs, la présence de multicolinéarité dans le modèle linéaire généralisé rend le modèle instable. Ainsi, nous avons d'abord expérimenté l'indice d'importance des variables dans le modèle *Random Forest*, puis tenté de construire un modèle linéaire pour vérifier si les résultats des deux modèles concordaient.

2.3.3. Des idées principales concernant Random Forest et la Régression Logistique Multinomiale

Random Forest

Le *Random Forest* est un algorithme d'apprentissage automatique qui fait partie des méthodes d'*ensemble learning*, principalement utilisé pour des tâches de classification et de régression. Ce modèle consiste en un ensemble d'arbres de décision (ou *decision trees*) et son résultat final est déterminé soit par un vote majoritaire (pour la classification), soit par la moyenne des résultats (pour la régression).

Voici les caractéristiques principales du Random Forest :

- **Construction de plusieurs arbres de décision** : Au lieu de construire un seul arbre, le Random Forest génère un grand nombre d'arbres à partir de sous-échantillons des données d'entraînement.

- **Échantillonnage bootstrap** : Chaque arbre est construit à partir d'un sous-échantillon des données choisi par la méthode bootstrap, ce qui signifie que des exemples peuvent être répétés dans les échantillons.
- **Sélection aléatoire des variables** : Lors de la construction de chaque arbre, un sous-ensemble aléatoire des variables est choisi pour décider quelle variable divisera chaque nœud de l'arbre, réduisant ainsi la corrélation entre les arbres et augmentant la précision globale.
- **Réduction du surapprentissage** : Grâce à la combinaison de l'échantillonnage bootstrap et de la sélection aléatoire des variables, le Random Forest est moins susceptible de surapprendre (*overfitting*) par rapport à un arbre de décision unique.

Une des principales forces du Random Forest est sa capacité à évaluer l'*importance des variables*, c'est-à-dire à quantifier l'influence de chaque variable sur le résultat du modèle. Les deux principales méthodes pour mesurer cette importance sont :

- **Diminution moyenne de l'impureté (Mean Decrease Impurity)** : Cette méthode mesure l'importance d'une variable en fonction de la réduction moyenne de l'impureté (par exemple, l'indice de Gini) lorsque cette variable est utilisée pour diviser un nœud.
- **Diminution moyenne de la précision (Mean Decrease Accuracy)** : Cette méthode évalue la diminution de la précision du modèle lorsqu'une variable est retirée ou perturbée. Si la suppression d'une variable entraîne une diminution significative de la précision, elle est considérée comme importante.

Régression Logistique Multinomiale

La *Régression Logistique Multinomiale* est une extension de la régression logistique classique utilisée lorsque la variable cible comporte plus de deux catégories. Contrairement à la régression logistique binaire, ce modèle permet de modéliser les probabilités pour chaque classe d'appartenance.

L'équation de la régression logistique multinomiale pour chaque classe k est donnée par :

$$P(y = k|X) = \frac{\exp(X\beta_k)}{\sum_{k'} \exp(X\beta_{k'})}$$

où :

- $P(y = k|X)$ est la probabilité que la variable cible y appartienne à la classe k .
- X est le vecteur des variables explicatives.
- β_k est le vecteur des coefficients associés à la classe k .

L'objectif est de trouver les valeurs optimales des β_k qui maximisent la vraisemblance du modèle (*maximum likelihood*) à partir des données d'entraînement.

Critère de sélection StepAIC

Dans le cadre de la régression logistique, le choix des variables explicatives pertinentes est crucial pour éviter le surapprentissage et obtenir un modèle à la fois simple et interprétable. Le critère *Akaike Information Criterion* (AIC) est une mesure utilisée pour évaluer la qualité d'un modèle statistique en tenant compte de son degré de complexité. La formule de l'AIC est :

$$AIC = 2k - 2\ln(L)$$

où :

- k est le nombre de paramètres dans le modèle.
- L est la vraisemblance du modèle.

La méthode *Stepwise AIC* permet de sélectionner les variables du modèle en ajoutant ou en supprimant des variables à chaque étape pour minimiser l'AIC. Il existe deux approches :

- **Sélection avant (Forward Selection)** : On commence avec un modèle simple, puis on ajoute des variables une par une en conservant celles qui réduisent l'AIC.
- **Élimination arrière (Backward Elimination)** : On commence avec toutes les variables dans le modèle, puis on supprime celles qui ne contribuent pas de manière significative à la réduction de l'AIC.
- **Méthode mixte (Both)** : Cette approche combine les deux méthodes ci-dessus. À chaque étape, elle permet soit d'ajouter, soit de supprimer des variables afin d'optimiser le modèle en fonction de l'AIC. La méthode mixte est particulièrement utile lorsqu'il est difficile de déterminer au préalable si une variable doit être ajoutée ou supprimée du modèle, permettant ainsi une sélection plus flexible et efficace.

L'utilisation de la fonction `stepAIC` avec l'option `direction = "both"` dans R permet d'obtenir un modèle optimisé en termes de compromis entre la précision et la complexité.

Chapitre 3 : Résultats

3.1. Pour tous étudiants

Modèle Randomforest

```
# Supprimer les variables non nécessaires
insa_cleaned_3 <- insa_cleaned_2 %>%
  dplyr::select(-RATRAPAGES, -REDOUBLEMENT, -CLASSEMENTDERNIER, -CLASSEMENT1A)
insa_cleaned_3 <- droplevels(insa_cleaned_3)
```

```
# Vérifier les variables restantes
glimpse(insa_cleaned_3, width = 80)
```

```
set.seed(151)

rf_model_tous <- randomForest(SENSATIONREUSSITE ~ ., data = insa_cleaned_3,
                              mtry = 6, ntree = 1000, nodesize = 10, importance = TRUE)

varImpPlot(rf_model_tous,
            sort = TRUE,
            n.var = 15,
            main = "Importance des variables")
```

Importance des variables




Figure 3: Importance des variables pour tous étudiant

Cas 1 : Variable avec MeanDecreaseAccuracy élevé mais MeanDecreaseGini faible

Si une variable a un Mean Decrease Accuracy élevé mais un Mean Decrease Gini faible, cela signifie que cette variable est essentielle pour maintenir la précision du modèle, mais qu'elle n'est pas fréquemment utilisée pour diviser les données dans les arbres de décision. Cela peut se produire si la variable a une corrélation élevée avec la variable cible, mais n'est utilisée que dans un petit nombre de nœuds au sein des arbres de décision.

Cas 2 : Variable avec MeanDecreaseGini élevé mais MeanDecreaseAccuracy faible

À l'inverse, si une variable a un MeanDecreaseGini élevé mais un MeanDecreaseAccuracy faible, cela indique que cette variable est souvent utilisée pour effectuer des divisions efficaces dans le modèle, mais que sa suppression n'affecte pas de manière significative la précision globale du modèle. cela peut être dû à la multicolinéarité (une forte corrélation avec une ou plusieurs autres variables). Lorsqu'il existe plusieurs variables corrélées, le modèle peut ne pas dépendre d'une variable spécifique, car l'information qu'elle apporte est déjà fournie par d'autres variables. Les variables de ce type ont généralement de nombreuses modalités, ce qui les rend fréquemment utilisées pour aider à diviser les objets en sous-groupes plus petits.

Conclusion: Nous allons prioriser les variables ayant des valeurs élevées dans les deux indices, puis nous concentrer principalement sur les variables ayant des valeurs élevées dans l'indice MeanDecreaseAccuracy, car elles ont une forte corrélation avec la variable cible. De plus, nous pourrions également considérer les variables ayant des valeurs très élevées dans l'indice MeanDecreaseGini.

Sélection de modèle de régression logistique multinomiale

```
library(nnet)
library(MASS)
modele_complet_1<-multinom(SENSATIONREUSSITE ~.,data=insa_cleaned_3,trace =FALSE)

# Sélection du modèle avec stepAIC (méthode both)
modele_selection_1 <- stepAIC(modele_complet_1, direction = "both", trace = FALSE)

# Modèle sélectionné
print(modele_selection_1$call)

## multinom(formula = SENSATIONREUSSITE ~ STRESS + ETUDEDEHORS +
##          CONCENTRATIONPERSO + CONDITIONSTRAVAIL + ISOLEMENT + ALIMENTATION +
##          MOTIVATION + PROMO, data = insa_cleaned_3, trace = FALSE)
```

```

plot1 <- chi_square_test_and_plot(insa_cleaned_3, "MOTIVATION", "SENSATIONREUSSITE")

## P-value du test Chi-deux: MOTIVATION et SENSATIONREUSSITE = 9.999e-05

## Warning: 'aes_string()' was deprecated in ggplot2 3.0.0.
## i Please use tidy evaluation idioms with 'aes()'.
## i See also 'vignette("ggplot2-in-packages")' for more information.
## This warning is displayed once every 8 hours.
## Call 'lifecycle::last_lifecycle_warnings()' to see where this warning was
## generated.

plot2 <- chi_square_test_and_plot(insa_cleaned_3, "STRESS", "SENSATIONREUSSITE")

## P-value du test Chi-deux: STRESS et SENSATIONREUSSITE = 9.999e-05

plot3 <- chi_square_test_and_plot(insa_cleaned_3, "ISOLEMENT", "SENSATIONREUSSITE")

## P-value du test Chi-deux: ISOLEMENT et SENSATIONREUSSITE = 9.999e-05

plot4 <- chi_square_test_and_plot(insa_cleaned_3, "CONCENTRATIONPERSO", "SENSATIONREUSSITE")

## P-value du test Chi-deux: CONCENTRATIONPERSO et SENSATIONREUSSITE = 9.999e-05

plot5 <- chi_square_test_and_plot(insa_cleaned_3, "CONDITIONSTRAVAIL", "SENSATIONREUSSITE")

## P-value du test Chi-deux: CONDITIONSTRAVAIL et SENSATIONREUSSITE = 9.999e-05

plot6 <- chi_square_test_and_plot(insa_cleaned_3, "ALIMENTATION", "SENSATIONREUSSITE")

## P-value du test Chi-deux: ALIMENTATION et SENSATIONREUSSITE = 9.999e-05

plot7 <- chi_square_test_and_plot(insa_cleaned_3, "IMPLICATION_CM", "SENSATIONREUSSITE")

## P-value du test Chi-deux: IMPLICATION_CM et SENSATIONREUSSITE = 0.00339966

plot8 <- chi_square_test_and_plot(insa_cleaned_3, "IMPLICATION_TD", "SENSATIONREUSSITE")

## P-value du test Chi-deux: IMPLICATION_TD et SENSATIONREUSSITE = 0.00439956

plot9 <- chi_square_test_and_plot(insa_cleaned_3, "SPECIALITE_PO", "SENSATIONREUSSITE")

## P-value du test Chi-deux: SPECIALITE_PO et SENSATIONREUSSITE = 9.999e-05

grid.arrange(plot1, plot2, plot3,
              plot4, plot5, plot6,
              plot7, plot8, plot9,
              ncol = 3,
              layout_matrix = rbind(c(1, 2, 3),
                                    c(4, 5, 6),
                                    c(7, 8, NA),
                                    c(9,9,9)))

```

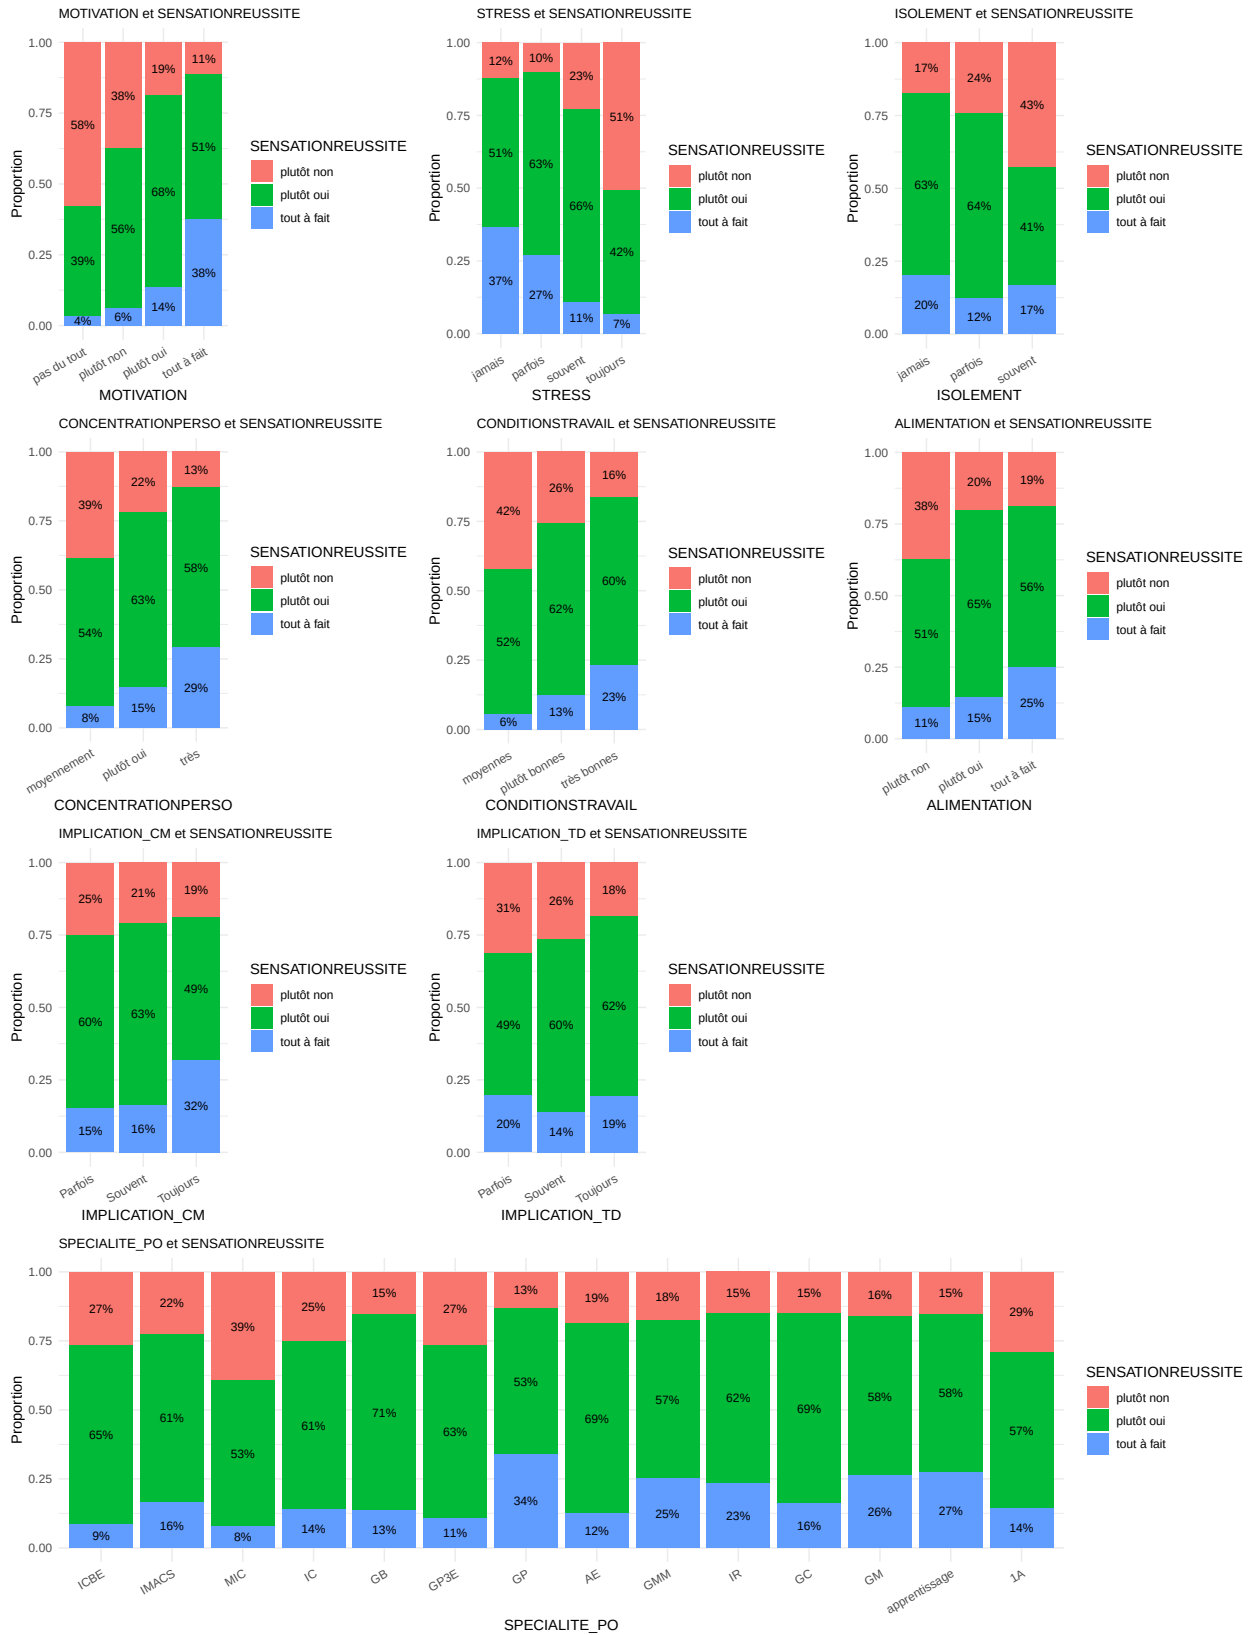


Figure 4: La corrélation entre la variable cible SENSATIONREUSSITE et les variables importantes du jeu de données pour l'ensemble des étudiants

Le graphique confirme que la variable SENSATIONREUSSITE est proportionnelle à MOTIVATION, CONCENTRATIONPERSO, CONDITIONSTRAVAIL et ALIMENTATION, et inversement proportionnelle à STRESS et ISOLEMENT. Les variables IMPLICATION_CM et IMPLICATION_TD ont un faible impact.

Les étudiants de première année et ceux en programmes PO perçoivent une réussite académique moindre que leurs camarades en quatrième et cinquième années. Cette différence s'explique par les trois premières années, souvent axées sur des cours de tronc commun exigeants, qui peuvent accroître les difficultés. En revanche, après avoir passé ces années de tronc commun, les étudiants semblent gagner en confiance en suivant des cours spécialisés dans leur domaine choisi, ce qui leur confère une plus grande assurance dans leur parcours académique. On peut également observer que, de manière notable, les étudiants de PO MIC sont ceux ayant la sensation de réussite la plus faible, tandis que parmi les spécialités, la spécialité GP3E est celle où les étudiants ressentent une réussite académique sensiblement inférieure par rapport à ceux des autres spécialités.

3.2. Pour les étudiants qui ne sont pas 1A ou nouveaux entrants (NE)

```
group2 <- insa_cleaned_2 %>% filter(PROMO != "1A" & PROMO != "INTEGRATION")
group2 <- group2 %>% mutate(COHORTE=fct_collapse(COHORTE, "non-classic" =
  c("FAS", "SHN", "NORG-IBER-ENG-AS", "Arts_Etude", "SupENR")))
group2 <- droplevels(group2)

rf_model_group2_full <- randomForest(RATTRAPAGES ~ ., data = group2,
  mtry = 16, ntree = 1000, importance = TRUE)
varImpPlot(rf_model_group2_full, sort = TRUE, n.var=15, main = "Importance des variables")
```

Importance des variables




Figure 5: Importance des variables pour groupe 2

Le graphique ci-dessus montre que les variables SENSATIONREUSSITE et RATRAPAGES sont étroitement liées. Par conséquent, il est logique d'utiliser la variable SENSATIONREUSSITE pour étudier tous les étudiants lorsqu'il n'est pas possible d'utiliser la variable RATRAPAGES.

De plus, nous constatons que les variables RATRAPAGES, SENSATIONREUSSITE, REDOUBLEMENT, CLASSEMENT1A et CLASSEMENTDERNIER sont fortement corrélées, au point de pouvoir être considérées comme décrivant le même phénomène. Pour cette raison, je vais supprimer les variables SENSATIONREUSSITE, REDOUBLEMENT, CLASSEMENT1A et CLASSEMENTDERNIER avant d'analyser RATRAPAGES, afin de pouvoir identifier d'autres variables qui influencent la réussite des étudiants.

```
# Suppression des variables ayant une influence trop forte
group2_reduced <- group2 %>%
dplyr::select(-SENSATIONREUSSITE,-REDOUBLEMENT,-CLASSEMENT1A,-CLASSEMENTDERNIER)
```

```
# Construire le modèle Random Forest
set.seed(1234) # Fixer le seed pour la reproductibilité
rf_model_group2_reduced <- randomForest(RATRAPAGES ~ ., data = group2_reduced,
ntree = 2000, nodesize = 10,importance = TRUE)
```

```
varImpPlot(rf_model_group2_reduced,
sort = TRUE,
n.var = 15, # Affiche les 15 variables les plus importantes
main = "Importance des variables (modèle réduit)")
```

Importance des variables (modèle réduit)




Figure 6: Importance des variables pour groupe 2 - modèle réduit

Sélection de modèle de régression logistique multinomiale

```
scope_variables <- paste(setdiff(colnames(group2_reduced), "RATTRAPAGES"), collapse = " + ")

modele_simple_2 <- multinom(RATTRAPAGES ~ 1, data = group2_reduced, trace = FALSE)

modele_selection_2 <- stepAIC(
  modele_simple_2,
  scope = as.formula(paste("~", scope_variables)),
  direction = "both",
  trace = FALSE)

print(modele_selection_2$call)
```

```
## multinom(formula = RATTRAPAGES ~ BACTYPE + CONCENTRATIONPERSO +
##   SPECIALITE_PO + INTEGRATION + ALIMENTATION + ASSOCIATIF +
##   ACT_PRO + ECRANS + ETUDEDEHORS, data = group2_reduced, trace = FALSE)
```

```
plot1 <- chi_square_test_and_plot(group2_reduced, "BACTYPE", "RATTRAPAGES")
```

```
## P-value du test Chi-deux: BACTYPE et RATTRAPAGES = 0.00029997
```

```
plot2 <- chi_square_test_and_plot(group2_reduced, "ISOLEMENT", "RATTRAPAGES")
```

```
## P-value du test Chi-deux: ISOLEMENT et RATTRAPAGES = 9.999e-05
```

```
plot3 <- chi_square_test_and_plot(group2_reduced, "STRESS", "RATTRAPAGES")
```

```
## P-value du test Chi-deux: STRESS et RATTRAPAGES = 0.00289971
```

```
plot4 <- chi_square_test_and_plot(group2_reduced, "AMIS", "RATTRAPAGES")
```

```
## P-value du test Chi-deux: AMIS et RATTRAPAGES = 0.00039996
```

```
plot5 <- chi_square_test_and_plot(group2_reduced, "ASSOCIATIF", "RATTRAPAGES")
```

```
## P-value du test Chi-deux: ASSOCIATIF et RATTRAPAGES = 0.00429957
```

```
plot6 <- chi_square_test_and_plot(group2_reduced, "CONCENTRATIONPERSO", "RATTRAPAGES")
```

```
## P-value du test Chi-deux: CONCENTRATIONPERSO et RATTRAPAGES = 0.00039996
```

```
plot7 <- chi_square_test_and_plot(group2_reduced, "CONDITIONSTRAVAIL", "RATTRAPAGES")
```

```
## P-value du test Chi-deux: CONDITIONSTRAVAIL et RATTRAPAGES = 0.0049995
```

```
plot8 <- chi_square_test_and_plot(group2_reduced, "ALIMENTATION", "RATTRAPAGES")
```

```
## P-value du test Chi-deux: ALIMENTATION et RATTRAPAGES = 9.999e-05
```

```
plot9 <- chi_square_test_and_plot(group2_reduced, "INTEGRATION", "RATTRAPAGES")
```

```
## P-value du test Chi-deux: INTEGRATION et RATTRAPAGES = 0.01719828
```

```
plot10 <- chi_square_test_and_plot(group2_reduced, "ACT_PRO", "RATTRAPAGES")
```

```
## P-value du test Chi-deux: ACT_PRO et RATTRAPAGES = 0.00719928
```

```
plot11 <- chi_square_test_and_plot(group2_reduced, "HANDICAP", "RATTRAPAGES")
```

```
## P-value du test Chi-deux: HANDICAP et RATTRAPAGES = 0.00539946
```

```
plot12 <- chi_square_test_and_plot(group2_reduced, "ECRANS", "RATTRAPAGES")
```

```
## P-value du test Chi-deux: ECRANS et RATTRAPAGES = 0.00419958
```

```
plot13 <- chi_square_test_and_plot(group2_reduced, "SPECIALITE_PO", "RATTRAPAGES")
```

```
## P-value du test Chi-deux: SPECIALITE_PO et RATTRAPAGES = 9.999e-05
```

```
grid.arrange(plot1, plot2, plot3,  
              plot4, plot5, plot6,  
              plot7, plot8, plot9,  
              plot10, plot11, plot12,  
              plot13, ncol = 3,  
              layout_matrix = rbind(c(1, 2, 3),  
                                     c(4, 5, 6),  
                                     c(7, 8, 9),  
                                     c(10, 11, 12),  
                                     c(13, 13, 13)))
```

Nous constatons que, dans le jeu de données des étudiants autres que ceux de première année ou nouveaux entrants, la variable cible RATTRAPAGES dépend des éléments suivants :

- Les étudiants étrangers présentent un nombre moyen de sessions de rattrapage plus élevé que les étudiants français.
- Les variables émotionnelles, telles qu'ISOLEMENT, STRESS et AMIS, ont également une influence sur les rattrapages.
- La variable RATTRAPAGES est inversement proportionnelle à la concentration lors du travail personnel et aux conditions de travail et d'alimentation.
- Les étudiants intégrant l'INSA sans passer directement après le bac ont une tendance à avoir un nombre de rattrapages légèrement supérieur à ceux qui entrent juste après le post-bac.
- Il existe une corrélation positive entre les rattrapages et l'engagement dans des activités professionnelles ainsi que le handicap, avec une légère corrélation liée au temps d'utilisation des appareils électroniques pour des activités non académiques.
- Concernant les différences entre les spécialités PO, les étudiants de la spécialité MIC affichent le plus grand nombre de rattrapages, suivis par ceux de la spécialité IC.




Figure 7: La corrélation entre la variable cible RATRAPAGES et les variables importantes de groupe 2

3.3. Pour les étudiants 4A

```
etudiants_4A <- subset(group2, PROMO == "4A")
etudiants_4A <- etudiants_4A[ , !(names(etudiants_4A) %in% c("PROMO"))]
etudiants_4A <- etudiants_4A %>%
  filter(!(SPECIALITE_PO %in% c("ICBE", "IMACS", "MIC", "IC")))
etudiants_4A <- droplevels(etudiants_4A)
```

De manière similaire au traitement du jeu de données précédent, je vais supprimer les variables SENSATIONREUSSITE, REDOUBLEMENT, CLASSEMENT1A et CLASSEMENTDERNIER avant d'analyser RATRAPAGES, afin de pouvoir identifier d'autres variables qui influencent la réussite des étudiants

```
etudiants_4A_reduced <- etudiants_4A %>%
  dplyr::select(-SENSATIONREUSSITE, -REDOUBLEMENT, -CLASSEMENT1A, -CLASSEMENTDERNIER)
```

```
set.seed(151)
rf_model_4A_reduced <- randomForest(RATRAPAGES ~ ., data = etudiants_4A_reduced,
  mtry = 8, nodesize = 5, ntree = 7000, importance = TRUE)
```

```
varImpPlot(rf_model_4A_reduced, sort = TRUE, n.var = 15,
  main = "Importance des variables (modèle réduit) ")
```

Importance des variables (modèle réduit)




Figure 8: Importance des variables pour étudiants 4A

Sélection de modèle de régression logistique multinomiale

```
modele_simple_3 <- multinom(RATTRAPAGES ~ 1, data = etudiants_4A_reduced, trace = FALSE)
modele_selection_3 <- stepAIC(
  modele_simple_3,
  scope = as.formula(paste("~", scope_variables)),
  direction = "both",
  trace = FALSE)

print(modele_selection_3$call)
```

```
## multinom(formula = RATTRAPAGES ~ IMPLICATION_TD + INTEGRATION +
##   DETENTE + IMPLICATION_CM + FAMILLE + COMMENTAIRE + HANDICAP,
##   data = etudiants_4A_reduced, trace = FALSE)
```

```
plot1 <- chi_square_test_and_plot(etudiants_4A_reduced, "IMPLICATION_CM", "RATTRAPAGES")
```

```
## P-value du test Chi-deux: IMPLICATION_CM et RATTRAPAGES = 0.09549045
```

```
plot2 <- chi_square_test_and_plot(etudiants_4A_reduced, "IMPLICATION_TD", "RATTRAPAGES")
```

```
## P-value du test Chi-deux: IMPLICATION_TD et RATTRAPAGES = 0.00109989
```

```
plot3 <- chi_square_test_and_plot(etudiants_4A_reduced, "IMPLICATION_TP", "RATTRAPAGES")
```

```
## P-value du test Chi-deux: IMPLICATION_TP et RATTRAPAGES = 0.1622838
```

```
plot4 <- chi_square_test_and_plot(etudiants_4A_reduced, "BACTYPE", "RATTRAPAGES")
```

```
## P-value du test Chi-deux: BACTYPE et RATTRAPAGES = 0.00889911
```

```
plot5 <- chi_square_test_and_plot(etudiants_4A_reduced, "FAMILLE", "RATTRAPAGES")
```

```
## P-value du test Chi-deux: FAMILLE et RATTRAPAGES = 0.1054895
```

```
plot6 <- chi_square_test_and_plot(etudiants_4A_reduced, "ISOLEMENT", "RATTRAPAGES")
```

```
## P-value du test Chi-deux: ISOLEMENT et RATTRAPAGES = 0.2222778
```

```
plot7 <- chi_square_test_and_plot(etudiants_4A_reduced, "ECRANS", "RATTRAPAGES")
```

```
## P-value du test Chi-deux: ECRANS et RATTRAPAGES = 0.01709829
```

```
plot8 <- chi_square_test_and_plot(etudiants_4A_reduced, "INTEGRATION", "RATTRAPAGES")
```

```
## P-value du test Chi-deux: INTEGRATION et RATTRAPAGES = 0.03009699
```

```

plot9 <- chi_square_test_and_plot(etudiants_4A_reduced, "HANDICAP", "RATTRAPAGES")

## P-value du test Chi-deux: HANDICAP et RATTRAPAGES = 0.01589841

plot10 <- chi_square_test_and_plot(etudiants_4A_reduced, "DETENTE", "RATTRAPAGES")

## P-value du test Chi-deux: DETENTE et RATTRAPAGES = 0.04429557

plot11 <- chi_square_test_and_plot(etudiants_4A_reduced, "COMMENTAIRE", "RATTRAPAGES")

## P-value du test Chi-deux: COMMENTAIRE et RATTRAPAGES = 0.2409759

plot12 <- chi_square_test_and_plot(etudiants_4A_reduced, "ASSOCIATIF", "RATTRAPAGES")

## P-value du test Chi-deux: ASSOCIATIF et RATTRAPAGES = 0.1274873

plot13 <- chi_square_test_and_plot(etudiants_4A_reduced, "COHORTE", "RATTRAPAGES")

## P-value du test Chi-deux: COHORTE et RATTRAPAGES = 0.8209179

plot14 <- chi_square_test_and_plot(etudiants_4A_reduced, "SPECIALITE_PO", "RATTRAPAGES")

## P-value du test Chi-deux: SPECIALITE_PO et RATTRAPAGES = 0.2775722

grid.arrange(plot1, plot2, plot3,
              plot4, plot5, plot6,
              plot7, plot8, plot9,
              plot10, plot11, plot12,
              plot13, plot14, ncol = 3,
              layout_matrix = rbind(c(1, 2, 3), c(4, 5, 6),
                                     c(7, 8, 9), c(10, 11, 12),
                                     c(13, 14, 14)))

```

Nous constatons que, pour le jeu de données des étudiants en quatrième année (4A), le nombre moyen de rattrapages par semestre dépend des facteurs suivants :

- IMPLICATION_CM et IMPLICATION_TD : concernant les cours magistraux (CM), les étudiants ayant un nombre de rattrapages élevé sont souvent ceux qui assistent aux CM soit de manière occasionnelle, soit systématique. Cela peut s'expliquer par le fait que ces étudiants, bien qu'ayant une bonne volonté et une assiduité, éprouvent des difficultés à comprendre les cours, ce qui les conduit à assister aux CM dans l'espoir de combler leurs lacunes, mais malgré cela, ils rencontrent des échecs. En revanche, pour les travaux dirigés (TD), les étudiants qui y assistent régulièrement ont tendance à avoir moins de rattrapages.
- Type de bac : les étudiants ayant un bac français équivalent étranger présentent un taux de rattrapages bien plus élevé par rapport à ceux ayant un bac français ou un bac étranger.
- Variables IMPLICATION_TP, FAMILLE, ISOLEMENT, ECRANS, INTEGRATION, HANDICAP, SPECIALITE_PO : bien que ces facteurs aient un impact sur le nombre de rattrapages, leur influence reste modérée.
- Variables DETEN, COMMENTAIRE, ASSOCIATIF et COHORTE : ces variables ne semblent pas affecter la variable cible RATTRAPAGES.




Figure 9: La corrélation entre la variable cible RATRAPAGES et les variables importantes du jeu de données des étudiant 4A

Chapitre 4 : Conclusion et discussion

4.1. Conclusion et recommandations

Les résultats de l'analyse de la variable SENSATIONREUSSITE révèlent que le sentiment de réussite des étudiants dépend en grande partie des perceptions subjectives de chacun. Cette variable est principalement influencée par des facteurs émotionnels, tels que la motivation (MOTIVATION), le stress (STRESS) et le sentiment d'isolement (ISOLEMENT). Elle est également impactée par la capacité de concentration lors des études autonomes (CONCENTRATIONPERSO), ainsi que par les conditions de vie comme le cadre de travail (CONDITIONSTRAVAIL) et l'alimentation (ALIMENTATION). Enfin, la participation à des études en dehors de la maison ou en groupe (ETUDEDEHORS et ETUDEGROUPE, étroitement corrélées) apporte une dimension supplémentaire liée au sentiment d'isolement. En résumé, les résultats des deux modèles utilisés sont très proches et ne révèlent rien d'inhabituel.

Pour le groupe 2, on observe que la moyenne du nombre de matières à repasser est également fortement influencée par la variable BACTYPE (ce qui nous permet de distinguer entre les étudiants français et étrangers), par les émotions ou la vie sociale des étudiants (ISOLEMENT, STRESS, AMIS, ASSOCIATIF). De plus, cette variable dépend de SPECIALITE_PO, CONCENTRATIONPERSO et, dans une moindre mesure, de CONDITIONSTRAVAIL, ALIMENTATION, INTEGRATION, ACT_PRO, HANDICAP, ECRANS.

Enfin, pour les étudiants en quatrième année, l'implication dans les cours magistraux et travaux dirigés (CM, TD) se révèle importante. Une fois de plus, nous observons une influence notable des variables émotionnelles telles que BACTYPE (relatif au statut d'étudiant étranger), FAMILLE, ISOLEMENT, ainsi que d'autres variables moins importantes comme SPECIALITE_PO, ECRANS, INTEGRATION, HANDICAP.

En conclusion,

Tout d'abord, on peut voir que les modèles appliqués à différents ensembles de données soulignent l'importance de la motivation académique et du bien-être émotionnel pour prévenir le stress et l'isolement des étudiants, éléments clés pour leur sensation de réussite et leur succès académique, en particulier pour les étudiants internationaux. Voici quelques recommandations pour renforcer ces aspects :

- Encourager les étudiants à participer à des clubs, car plus de 90 % des étudiants ont indiqué que la participation aux clubs a un impact positif sur leur bien-être général, bien que moins de 50 % y participent. Cela pourrait s'expliquer par le fait que les clubs offrent aux étudiants l'opportunité de se socialiser et de se faire des amis, ce qui diminue leur isolement et réduit leur stress en leur offrant des activités à l'extérieur de leur chambre.
- Pour les cours nécessitant des travaux de groupe, il pourrait être bénéfique que les enseignants constituent des groupes de manière aléatoire, en intégrant les étudiants internationaux dans différents groupes afin de leur permettre de nouer des relations avec leurs pairs. En effet, les nouveaux étudiants qui rejoignent l'établissement à partir de la troisième année peuvent trouver qu'il est difficile de se faire des amis, en particulier parmi les étudiants français qui ont déjà constitué leurs cercles d'amis. Les interactions de groupe aident ainsi à réduire l'isolement et le stress des étudiants internationaux, tout en leur permettant de pratiquer le français et de gagner en confiance.
- Organiser des activités favorisant l'intégration et l'entraide pour les étudiants qui n'ont pas intégré l'INSA dès la première année afin de leur faciliter la familiarisation avec leurs camarades et les étudiants plus anciens.
- Surveiller régulièrement la fréquentation des cours par les étudiants. Si un étudiant manque fréquemment les cours et ne participe à aucune activité de groupe, il peut être utile d'identifier les raisons, car il pourrait s'agir de problèmes de santé physique ou mentale, notamment chez les étudiants internationaux.

Ensuite, nous constatons, en particulier pour les étudiants de quatrième année, que l’implication dans les cours est également cruciale. Cela correspond à mon expérience personnelle à l’INSA où les matières pour lesquelles j’assistais régulièrement aux cours produisaient des résultats meilleurs, par rapport à celles où les absences s’accumulaient, car les révisions de dernière minute pouvaient entraîner une surcharge de travail avant les examens. Une solution possible serait de faire l’appel dans les séances de TD/TP, même lorsque la présence n’est pas notée. Cela inciterait les étudiants à être plus assidus, et les enseignants pourraient ainsi identifier ceux qui s’absentent souvent pour comprendre les raisons. Par ailleurs, l’assiduité permettrait aux étudiants de se sociabiliser et de limiter le stress en rompant avec l’isolement lié à la solitude.

De plus, afin de mieux comprendre les écarts de performance entre les spécialités et les programmes PO, il serait pertinent de réaliser des enquêtes auprès des étudiants pour identifier les principales causes de leurs échecs aux examens. Cette démarche permettrait de concevoir des solutions adaptées et ciblées pour réduire le nombre de rattrapages et soutenir leur réussite académique.

Enfin, bien que l’analyse descriptive montre que les conditions de vie des étudiants de notre établissement — en termes de travail, d’alimentation et de transport — sont généralement bonnes pour la plupart, certains étudiants rencontrent tout de même des difficultés à cet égard, ce qui affecte leur réussite académique. De plus, les étudiants en situation de handicap connaissent un nombre de rattrapages plus élevé que leurs pairs. Pour remédier à cela, il serait pertinent de mettre en place des enquêtes régulières afin d’identifier rapidement les conditions de vie difficiles de certains étudiants et de pouvoir proposer des solutions d’aide en temps opportun.

4.2. Limites et améliorations futures

La conception de l’enquête avec de nombreuses questions sur le même thème, et surtout des questions dont les réponses dépendent d’autres questions précédentes, a entraîné des corrélations fortes entre les variables, rendant l’analyse des données et la construction de modèles plus complexes. En outre, une limite personnelle est mon manque d’expérience dans le traitement de nombreuses variables qualitatives interconnectées, ce qui m’a conduit à suivre des cours de base pour le traitement de données (certificats en annexe B). De plus, j’ai dû tester les modèles plusieurs fois pour détecter des erreurs, entraînant une perte de temps considérable. Une solution pourrait consister à réduire les questions redondantes dans les enquêtes et à ne poser qu’une seule question par thème.

En observant que quatre variables (CLASSEMENTDERNIER, REDOUBLEMENT, RATRAPAGES, SENSATIONREUSSITE) sont fortement corrélées, nous pourrions envisager la création d’une variable résultats global qui permettrait d’évaluer les étudiants sous différents aspects.

En outre, certaines variables présentent des écarts de pourcentage importants entre les modalités, qui ne peuvent pas être regroupées, comme les variables décrivant le tiers temps ou le handicap, avec seulement deux choix possibles : oui ou non. Par ailleurs, le regroupement de modalités à faible fréquence et de signification proche, comme nous l’avons fait, entraîne également une perte d’informations. Il est donc nécessaire d’explorer des solutions pour résoudre ce problème et créer un jeu de données plus équilibré pour la construction de modèles, ce qui permettra d’assurer une meilleure stabilité.

Annexe A: Statistique descriptive

Les distributions illustrant les affirmations en statistiques descriptives, y compris la distribution des variables IMPLICATION_CM, IMPLICATION_TD et IMPLICATION_TP, ont été affichées après l'agrégation des variables.




Figure 10: Distribution des variables sur les conditions de vie




Figure 11: La distribution des variables sur la participation à la vie associative




Figure 12: Distribution des variables sur la santé mentale

Annexe B: Certificat de cours



Références

1. Détourbe, M.-A. (2014). The quality of the students learning experience: A strategic dimension of british and american higher education systems in the early 21st century. In *Higher education in the UK and the US* (pp. 165–196). Brill.
2. Brooker, A., & Vu, C. (2020). How do university experiences contribute to students' psychological wellbeing? *Student Success*, 11(2), 99–108.